RAPPORT DE PROJET

Segmentation Sémantique de Déchets par Deep Learning

Apprentissage automatique appliqué à la reconnaissance de matériaux recyclables

Mars 2026

Mohamed Habib BAH, Thibaud LECOMTE

1. Présentation générale du projet

1.1 Contexte et objectif

Ce projet s'inscrit dans le domaine du recyclage assisté par vision par ordinateur. L'objectif principal est de construire un système capable de segmenter sémantiquement des images de déchets : identifier, pixel par pixel, à quelle matière appartient chaque région de l'image (plastique, carton, métal, etc.).

Ce type de tâche est plus difficile que la simple classification d'image, car le modèle doit produire un masque de la même résolution que l'image d'entrée, avec une étiquette de classe pour chaque pixel. C'est le fondement technique des systèmes de tri automatisé sur tapis roulants industriels.

1.2 Architecture choisie : U-Net ResNet-18

L'architecture utilisée tout au long du projet est un U-Net dont l'encodeur est un ResNet-18 pré-entraîné sur ImageNet. Ce choix résulte d'un compromis entre puissance de représentation et contraintes matérielles (entraînement sur CPU).

Le ResNet-18 agit comme extracteur de features hiérarchiques (textures, formes, contours). Le décodeur U-Net réassemble ces features à la résolution originale via des skip connections. L'encodeur est dégelé pour permettre un ajustement fin des features aux déchets, avec un learning rate différentiel : 10× plus faible pour l'encodeur que pour le décodeur, afin de ne pas effacer les features ImageNet acquises en pré-entraînement.

La fonction de perte combine une Focal Loss (γ=2.0) et une Dice Loss à parts égales. La Focal Loss pénalise plus fortement les erreurs sur les classes difficiles ou rares. La Dice Loss maximise directement l'overlap entre prédiction et vérité terrain, ce qui est adapté aux classes déséquilibrées en pixels.

1.3 Deux datasets, trois expériences

Trois configurations d'entraînement ont été testées :

- Garbage Classification seul : images individuelles sur fond blanc, masques générés automatiquement, scènes composites artificielles, 7 classes.
- ZeroWaste-f seul : vraies scènes de tri industriel, masques fournis, 5 classes.
- Fusion des deux datasets : combinaison des deux sources avec harmonisation des classes sur un référentiel commun à 5 classes.

2. Dataset Garbage Classification — Apprentissage seul

2.1 Présentation du dataset

Le dataset Garbage Classification (disponible sur Kaggle) est composé d'images individuelles de déchets photographiés sur fond blanc uni. Chaque image contient un seul objet centré, bien éclairé, sans occlusion. Les 7 classes initiales sont : verre (glass), carton (cardboard), papier (paper), plastique (plastic), métal (metal), poubelle (trash), et fond (background).

Ce dataset présente un avantage immédiat pour la génération de masques automatique : le fond blanc uniforme permet d'isoler l'objet par simple seuillage des canaux couleur (BGR threshold). Il présente en revanche une faiblesse fondamentale pour la segmentation en conditions réelles : les objets ne se superposent jamais, et les images sont trop homogènes pour représenter la variété d'une scène industrielle.

2.2 Génération automatique des masques

En l'absence de masques annotés dans ce dataset, une approche de génération automatique a été développée. L'algorithme combine seuillage BGR par classe, fermeture morphologique, remplissage de trous par flood fill inversé, et conservation du plus grand composant connexe.

Des seuils différenciés par classe (BGR_THRESHOLDS dans config.py) ont été calibrés manuellement : verre à 230, carton à 220, papier à 200, plastique à 215, métal à 210. Un fallback basé sur les contours Canny est activé si le masque résultant couvre moins de 1% de l'image, ce qui arrive typiquement sur le verre transparent.

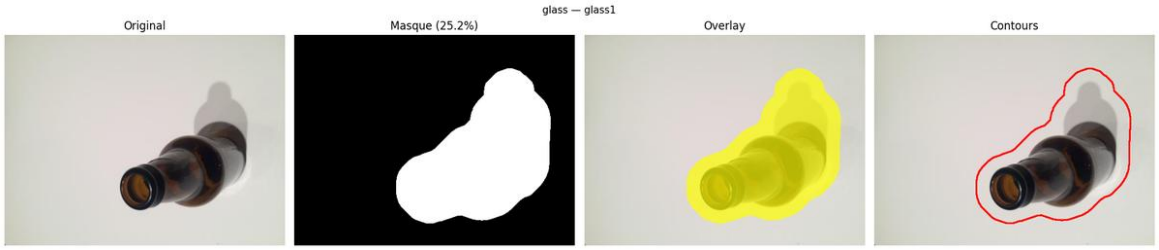

Figure 1 — Masque automatique généré pour la classe verre : image originale, masque binaire, classe sémantique superposée

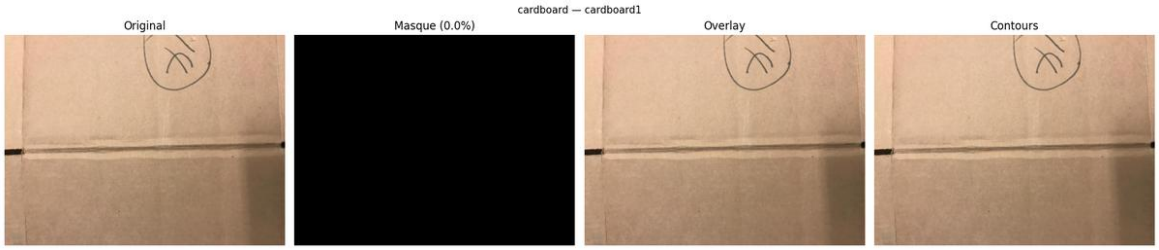

Figure 2 — Masque automatique pour la classe carton : détection fiable sur fond blanc

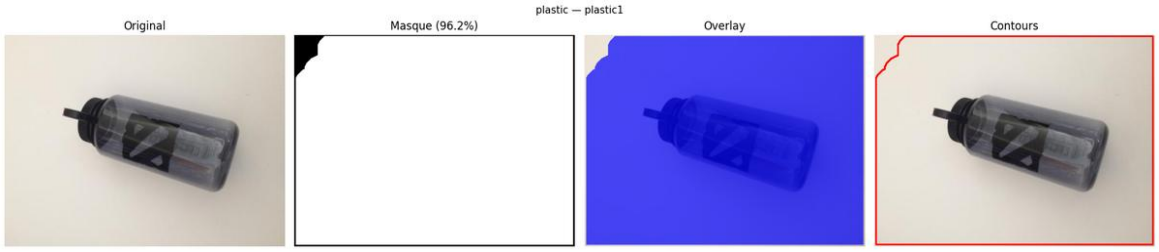

Figure 3 — Masque automatique pour la classe plastique

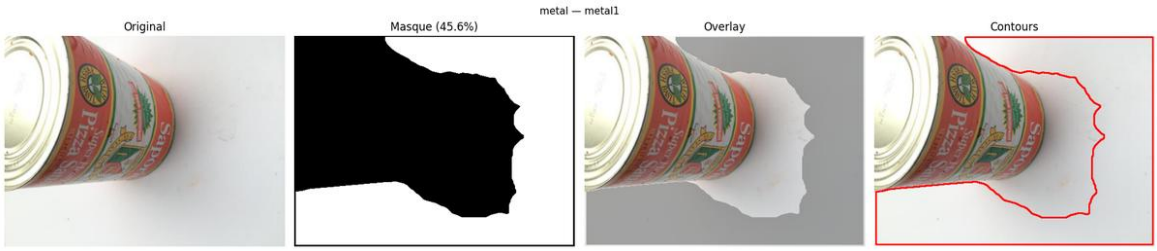

Figure 4 — Masque automatique pour la classe métal : les reflets brillants créent parfois des zones manquantes comblées par fermeture morphologique

2.3 Scènes composites artificielles

Puisque les images Garbage Classification ne montrent qu'un objet à la fois, un compositeur de scènes a été développé pour créer des images de formation avec plusieurs déchets. Le script (scene_composer.py) place aléatoirement des objets découpés sur un fond blanc, à trois niveaux de densité : sparse (3 objets), medium (6 objets), dense (12 objets).

Cette approche présente une limite importante qui s'est avérée critique pour les performances : le modèle est entraîné à reconnaître les objets sur fond blanc, mais ses masques binaires recouvrent systématiquement l'intégralité de l'objet découpé. Lors de l'évaluation sur les scènes composites, le modèle cherche des objets entiers, non des déchets partiellement occultés ou entremêlés. Les objets qui se superposent génèrent des erreurs de classification aux frontières.

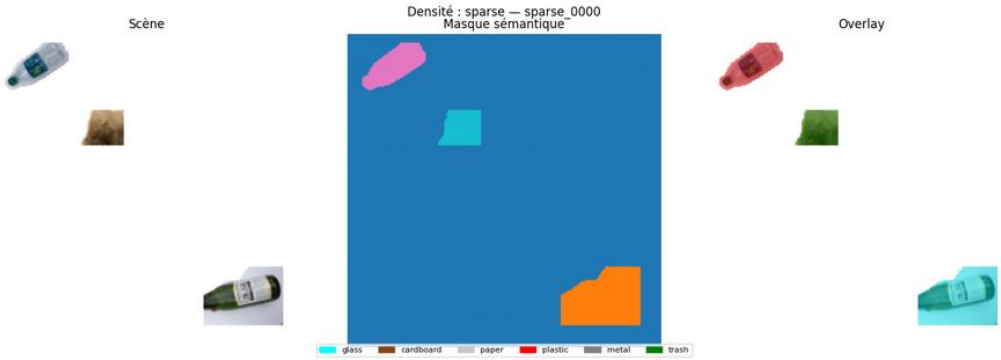

Figure 5 — Scène composite sparse (3 objets) : image construite + masque sémantique ground truth

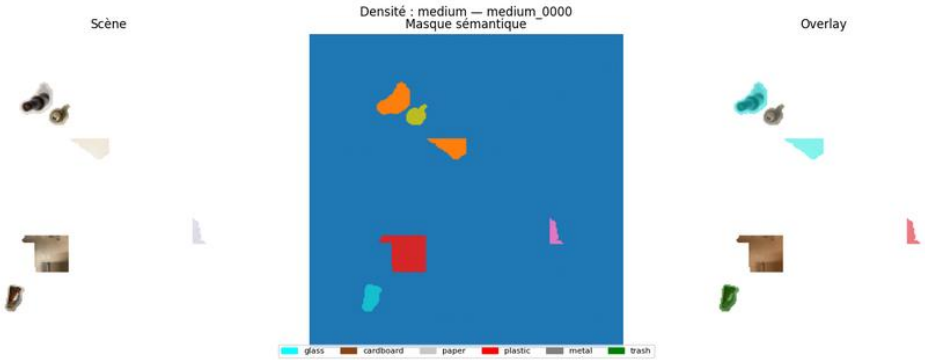

Figure 6 — Scène medium (6 objets) : les objets commencent à se chevaucher, rendant la segmentation plus difficile

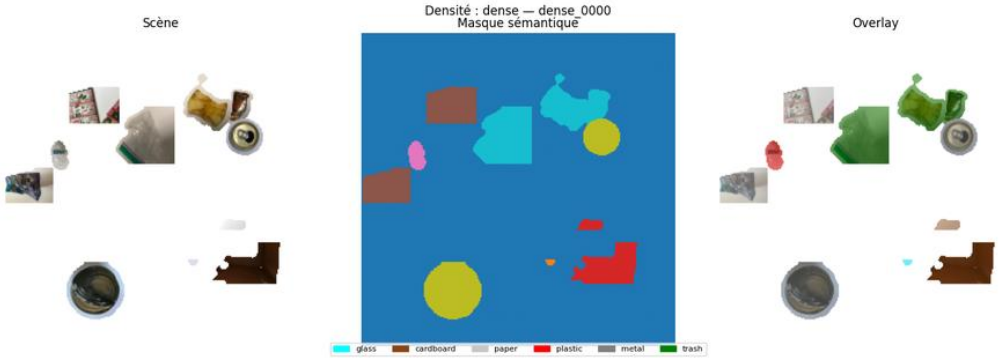

Figure 7 — Scène dense (12 objets) : forte densité, occlusions multiples — scénario le plus réaliste mais aussi le plus difficile

2.4 Résultats d'entraînement

L'entraînement sur scènes composites a été conduit sur 25 époques avec early stopping (patience 8). La loss combinée Focal + Dice converge régulièrement sans signe d'explosion de gradient.

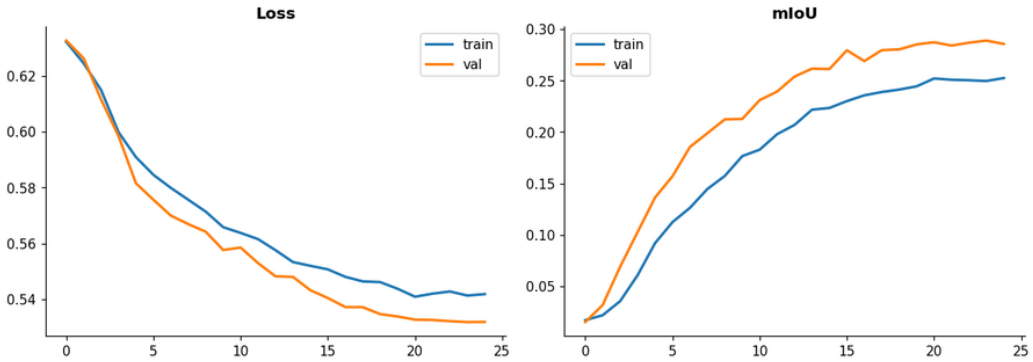

Figure 8 — Courbes d'entraînement Garbage Classification : loss et mIoU train/val sur 25 époques

Le mIoU de validation atteint 0.289 en fin d'entraînement. Ce résultat reflète le déséquilibre entre classes : background et cardboard sont faciles à segmenter, tandis que glass et trash restent difficiles.

Densité	mIoU	Accuracy	IoU Cardboard	IoU Glass
Sparse	0.316	85.0%	0.414	0.015
Medium	0.300	76.7%	0.470	0.006
Dense	0.290	64.9%	0.462	0.012

Tableau 1 — Métriques par niveau de densité des scènes composites

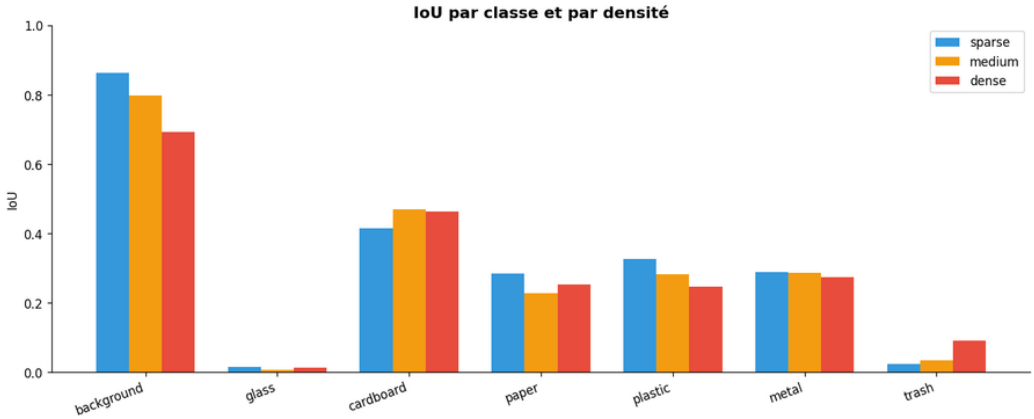

Figure 9 — IoU par classe sur les scènes composites : cardboard et paper dominent, glass et trash quasi absents

On observe une dégradation progressive des métriques avec la densité : le mIoU passe de 0.316 (sparse) à 0.290 (dense), et la précision pixel chute de 85% à 65%. Cette tendance est attendue : plus les objets se superposent, plus les frontières de segmentation deviennent ambiguës. La classe trash est particulièrement mal reconnue car elle est visuellement hétérogène (pas de texture ou forme caractéristique).

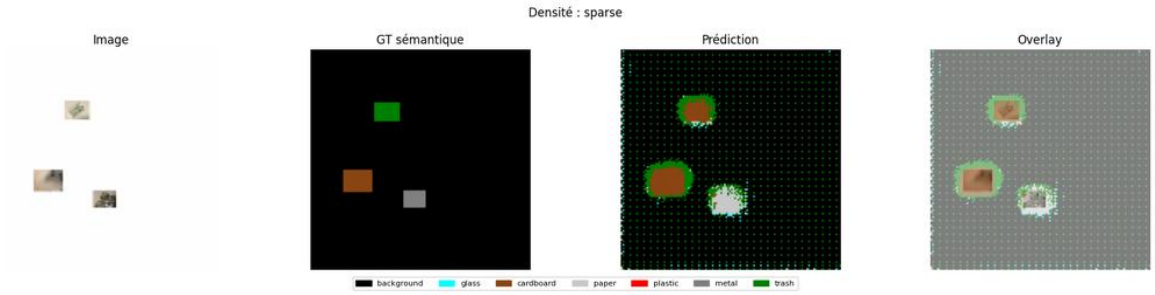

Figure 10 — Prédictions sur scène sparse : le fond et le carton sont bien segmentés, mais les objets avec textures similaires sont confondus

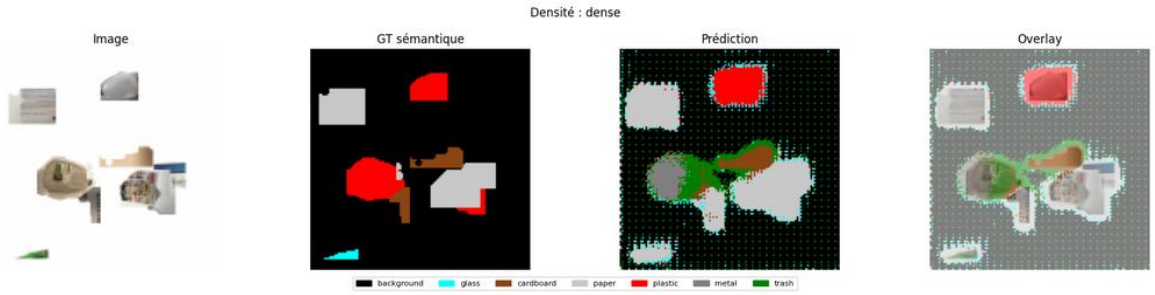

Figure 11 — Prédictions sur scène dense : les confusions augmentent aux frontières des objets superposés

2.5 Tentative de masques YOLO

Contexte et motivation

La génération de masques par seuillage BGR présentée en section 2.2 produit des régions rectangulaires approximatives plutôt que des contours précis épousant la forme réelle de l'objet. Pour le verre transparent ou les objets à géométrie complexe, ces masques rectangulaires constituent une vérité terrain de mauvaise qualité : le modèle est entraîné à délimiter un rectangle plutôt que l'objet lui-même. Cette limitation a motivé l'exploration de YOLO v8, capable de produire des masques d'instance basés sur les contours réels des objets.

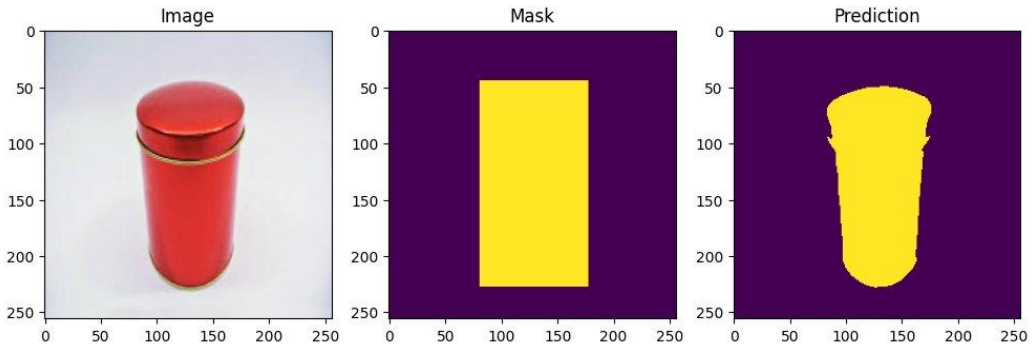

Figure A — Canette Coca-Cola : le masque GT (rectangle jaune issu du seuillage) couvre une zone rectangulaire incluant du fond, tandis que la prédiction délimite correctement la forme cylindrique de la canette

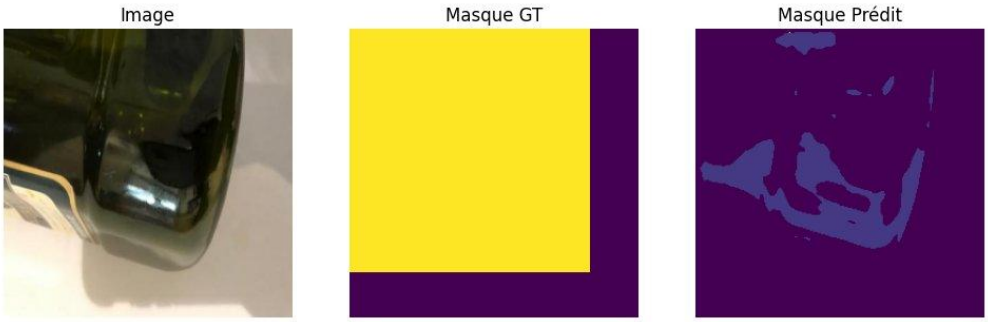

Figure B — Boîte métallique rouge : cas favorable où le masque rectangulaire et la forme réelle sont proches — la prédiction suit fidèlement les contours du cylindre

Le problème central : la conversion de format

YOLO v8 en mode segmentation produit des masques d'instance encodés sous forme de polygones normalisés (coordonnées relatives à la taille de l'image, entre 0 et 1). Ce format est conçu pour la détection d'instances individuelles, c'est-à-dire identifier chaque objet séparément avec sa propre étiquette et son propre masque. Le U-Net, en revanche, attend des masques sémantiques pixel-par-pixel : chaque pixel de l'image reçoit directement un indice de classe (0 pour fond, 1 pour rigid_plastic, etc.), sans distinction d'instances.

La conversion entre ces deux formats n'est pas triviale. Elle nécessite de rasteriser les polygones YOLO sur une grille de la taille de l'image, puis de résoudre les conflits de chevauchement : si deux instances se superposent (deux déchets qui se touchent), quel label sémantique assigner aux pixels couverts par les deux masques ? YOLO ne fournit pas de réponse à cette question — c'est à l'utilisateur de définir une politique de fusion.

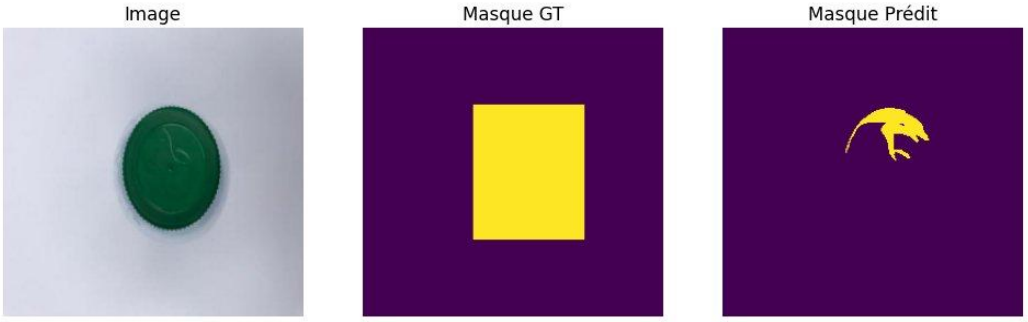

Figure C — Magazines empilés : le masque GT rectangulaire couvre l'intégralité de la pile, mais la prédiction fragmente la détection car les textures variées des couvertures créent des ambiguïtés visuelles importantes

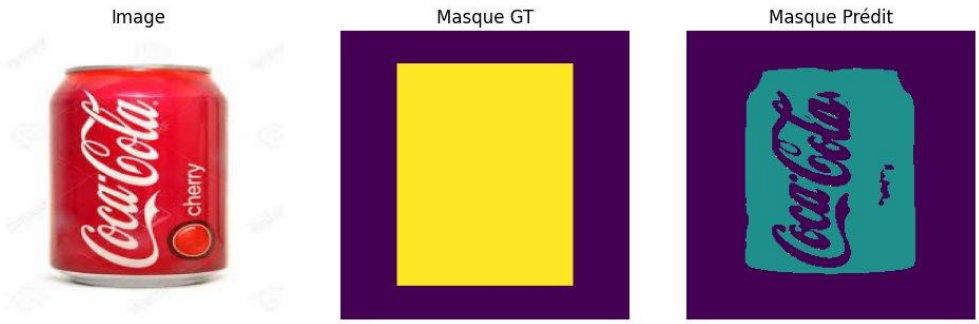

Figure D — Bouchon de bouteille vert à plat : objet sans relief marqué — la prédiction ne détecte que les gravures du logo en surface, manquant complètement la forme globale du bouchon, ce qui illustre la difficulté des objets peu contrastés par rapport au fond

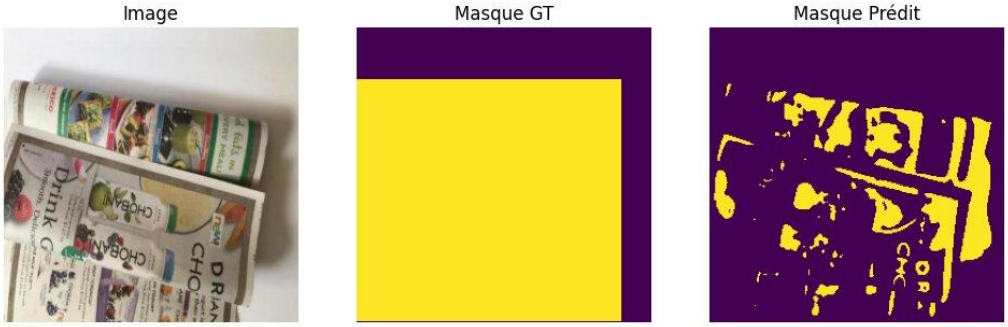

Figure E — Bouteille en verre sombre : la transparence partielle du verre et les reflets créent des valeurs de pixels ambiguës — la prédiction fragmente la segmentation en plusieurs zones non cohérentes

Problèmes de qualité observés

Au-delà de la conversion de format, les visualisations révèlent des problèmes de qualité qui auraient persisté même après conversion :

- Masques GT trop approximatifs (images A, C, E) : le seuillage BGR produit des rectangles qui incluent du fond autour de l'objet. Entraîner un modèle sur cette vérité terrain lui apprend à délimiter des boîtes, non des objets réels. YOLO ne résout pas ce problème fondamental car la précision de son masque dépend de la qualité de ses propres annotations d'entraînement.
- Objets non contrastés (image D) : les objets plats, foncés, ou de couleur proche du fond (comme le bouchon vert sur fond gris clair) produisent des détections fragmentées quel que soit la méthode de masque, car c'est le contraste visuel qui conditionne la détection.
- Verre et transparences (image E) : YOLO et le seuillage souffrent tous deux du même problème sur le verre — les pixels transparents ont des valeurs similaires au fond, rendant la délimitation intrinsèquement ambiguë sans information contextuelle supplémentaire.

Conclusion sur l'abandon

L'abandon de l'approche YOLO résulte de la combinaison de ces facteurs : complexité du pipeline de conversion (polygones → masques sémantiques → gestion des chevauchements), absence de gain de qualité démontrable sur les cas difficiles (verre, objets plats), et adéquation suffisante du seuillage BGR pour les images Garbage Classification sur fond blanc où les objets sont bien contrastés et non occultés. Le temps de développement nécessaire à une intégration propre de YOLO n'était pas justifié dans le cadre du projet, d'autant que le problème principal identifié par la suite était le déséquilibre de classes et la différence de domaine entre datasets, deux problèmes indépendants de la qualité des masques.

2.6 Limites de l'approche Garbage Classification seul

L'entraînement sur scènes composites artificielles génère un modèle qui apprend à reconnaître des objets complets sur fond blanc uniforme. En conditions réelles (fond texturé, éclairage variable, objets déformés), les performances chutent significativement car la distribution des données d'entraînement est trop éloignée de la réalité industrielle. Ce constat a motivé l'introduction du dataset ZeroWaste.

3. Dataset ZeroWaste-f — Apprentissage seul

3.1 Présentation du dataset

ZeroWaste-f est un dataset de segmentation sémantique de déchets industriels capturé sur un vrai tapis roulant de tri. Il comprend 4 503 images annotées pixel par pixel, réparties en train (3 176), val (572) et test (929) selon les splits officiels. Les 5 classes sont : background (tapis roulant), rigid_plastic (plastique rigide), cardboard (carton/papier), metal (métal), soft_plastic (plastique souple, sachets).

La principale caractéristique de ce dataset est sa provenance vidéo : les images sont extraites de séquences filmées en continu sur le tapis. Deux images consécutives peuvent être quasi-identiques, ce qui crée un risque de fuite de données entre train et test si des frames successifs se retrouvent dans les deux splits.

3.2 Problème de similarité inter-frames

Une analyse par hash perceptuel (phash, 16×16 bits) a été menée pour quantifier la redondance entre frames. L'histogramme des distances de Hamming entre images consécutives révèle qu'une fraction significative des paires ont une distance inférieure à 20/256, ce qui indique des scènes quasi-identiques.

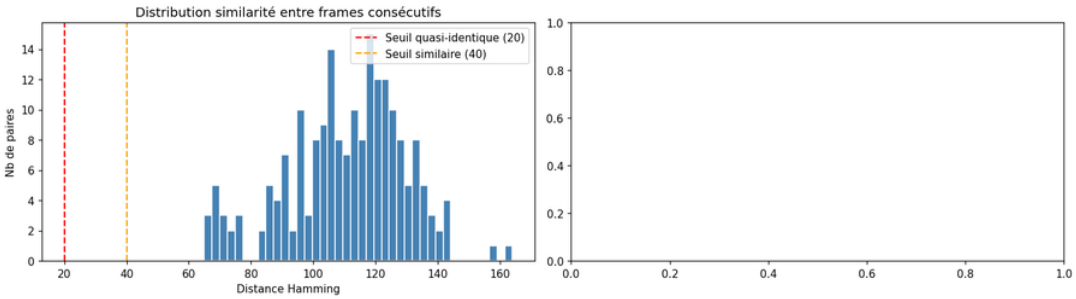

Figure 12 — Distribution des distances de Hamming entre frames consécutifs de ZeroWaste : la concentration à gauche indique une forte redondance temporelle

Pour limiter cet effet, un script de curation (curate_dataset.py) a été développé pour sélectionner des images maximisant la diversité visuelle via un algorithme greedy : partir d'une image, puis ajouter à chaque étape l'image la plus différente de celles déjà sélectionnées (distance Hamming maximale avec son plus proche voisin dans la sélection courante). Les distances maintenues (102-122/256 sur 120 images) indiquent une bonne diversité.

Cependant, lors des expériences de fusion avec Garbage Classification, la réduction à 120-200 images a drastiquement limité les performances. Le dataset ZeroWaste original (4 503 images) a finalement été préféré malgré le risque de redondance, le volume de données étant plus critique que la diversité maximale pour un U-Net de cette taille.

3.3 Résultats d'entraînement ZeroWaste seul

L'entraînement sur le dataset ZeroWaste complet (splits officiels, 30 images par classe dominante sur train) a été conduit sur 18 époques avant déclenchement de l'early stopping (patience 8). Le meilleur val mIoU est de 0.222 à l'époque 10.

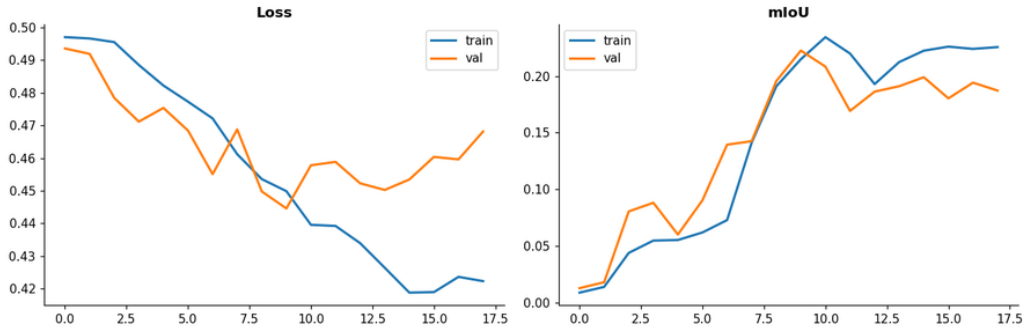

Figure 13 — Courbes d'entraînement ZeroWaste seul : la loss décroît régulièrement mais la val mIoU oscille, révélant une instabilité due au faible nombre d'images par classe

Les résultats sur le test set (929 images) sont les suivants :

Classe	IoU	F1	mIoU global	Accuracy
background	0.508	0.674	0.215	50.9%
rigid_plastic	0.010	0.020	—	—
cardboard	0.356	0.525	—	—
metal	0.006	0.012	—	—
soft_plastic	0.193	0.324	—	—

Tableau 2 — Résultats test ZeroWaste seul (mIoU global = 0.215, mIoU sans fond = 0.141)

La précision globale de 50.9% traduit un modèle qui commence à segmenter le fond correctement (IoU=0.508) et le carton de façon acceptable (0.356), mais qui échoue presque complètement sur metal (0.006) et rigid_plastic (0.010). Ces deux classes sont très rares en pixels (respectivement 0.3% et 0.7% du total) et visuellement similaires au fond ou aux plastiques souples.

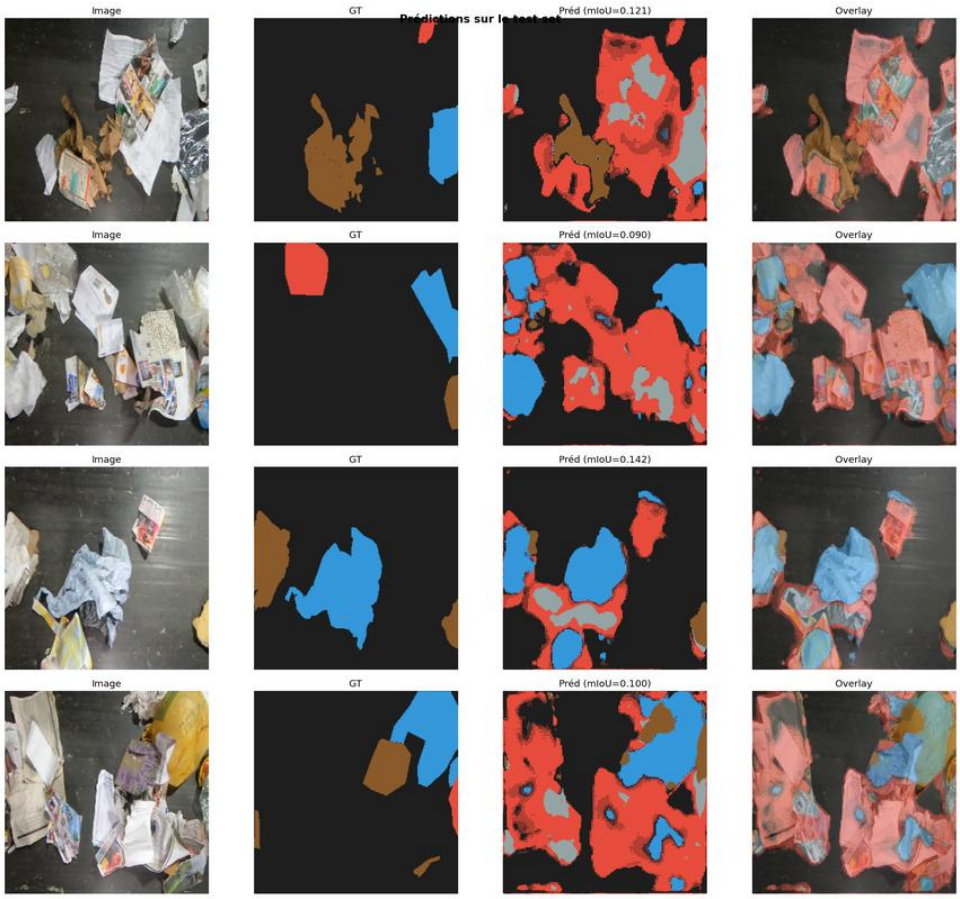

Figure 14 — Prédictions ZeroWaste seul sur 3 images test : le fond et le carton sont partiellement reconnus, mais metal et rigid_plastic sont quasi absents

3.4 Analyse des limites

L'entraînement ZeroWaste seul souffre de deux problèmes structurels. Premièrement, le déséquilibre de classes est extrême : background représente 83% des pixels dans le dataset, cardboard environ 10%, soft_plastic 5%, et metal moins de 0.3%. Même avec une Focal Loss, le modèle peut minimiser la loss globale en prédisant quasi-exclusivement background et cardboard. Deuxièmement, la limite de 30 images par classe dans le sampling de train crée une base d'apprentissage trop restreinte pour les classes rares.

4. Fusion des deux datasets

4.1 Motivation et défi de la fusion

La fusion vise à combiner les avantages des deux sources : la diversité d'objets individuels de Garbage Classification (fond blanc, une seule classe bien délimitée) et la réalité industrielle de ZeroWaste (fond texturé, plusieurs déchets visibles, vraies conditions de tri). L'enjeu est de construire un modèle généraliste capable de segmenter des déchets dans les deux contextes.

Cette fusion soulève cependant plusieurs défis techniques majeurs qui ont conditionné toutes les difficultés rencontrées.

4.2 Harmonisation des classes

Les deux datasets n'utilisent pas les mêmes classes. Garbage Classification propose 7 classes (glass, cardboard, paper, plastic, metal, trash, background) tandis que ZeroWaste en propose 5 (background, rigid_plastic, cardboard, metal, soft_plastic). Un mapping a été établi :

Garbage Classification	Classe unifiée	Justification	Indice
glass + plastic	rigid_plastic	Emballages rigides	1
cardboard + paper	cardboard	Fibres cellulosiques	2
metal	metal	Correspondance directe	3
trash	(ignoré)	Trop hétérogène	—
(absent)	soft_plastic	ZeroWaste uniquement	4

Tableau 3 — Mapping des classes Garbage Classification vers les 5 classes ZeroWaste

Ce mapping introduit une ambiguïté : glass (verre) et plastic (plastique rigide) reçoivent le même label, mais leurs apparences visuelles sont radicalement différentes. Le modèle doit apprendre que deux textures visuellement distinctes correspondent à la même étiquette sémantique, ce qui complexifie l'apprentissage.

La classe soft_plastic n'a pas d'équivalent dans Garbage Classification, ce qui signifie que le modèle ne voit cette classe qu'à travers ZeroWaste, en contexte multi-objets sur tapis roulant. La classe trash de Garbage Classification est ignorée car elle regroupe des déchets de natures trop diverses pour être mappée sur une classe ZeroWaste cohérente.

4.3 Problème du fond : un conflit de distributions

Le problème le plus persistant de la fusion est la confusion fond/objet. Dans Garbage Classification, le fond est un blanc uniforme (RGB ≈ 255,255,255) systématiquement absent des masques. Le modèle entraîné sur ce dataset a appris que "presque tous les pixels sont des objets". Face au tapis roulant de ZeroWaste (surface sombre et texturée), il ne reconnaît pas ce fond comme du background et le classifie en objet, principalement rigid_plastic ou soft_plastic.

Plusieurs tentatives de correction ont été menées : boost du poids de la classe background dans la loss (×2, ×2.5, ×5), augmentation du gamma de la Focal Loss (2.0 → 3.0), ajout d'une bordure de fond blanc autour des images Garbage (ratio 25% de chaque côté). Chaque correction a créé un effet de balancier : trop de poids background → tout prédit en background ; pas assez → fond prédit comme plastique.

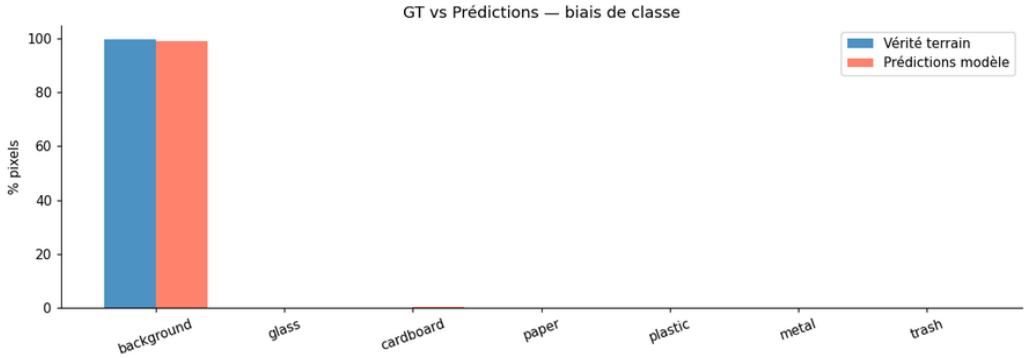

Figure 15 — Biais de prédiction détecté lors du diagnostic : le modèle prédit massivement cardboard ou background selon les réglages de poids

4.4 Déséquilibre des classes dans les données fusionnées

La fusion crée un déséquilibre supplémentaire par rapport à chaque dataset pris séparément. Rigid_plastic reçoit les contributions de glass ET plastic depuis Garbage Classification (soit 60 images potentielles contre 30 pour cardboard ou metal), ce qui le sur-représente. Pour corriger cela, le sampling a été modifié pour limiter à 30 images par classe CIBLE (pas par dossier source), ce qui plafonne rigid_plastic à 30 images indépendamment du nombre de dossiers sources qui y contribuent.

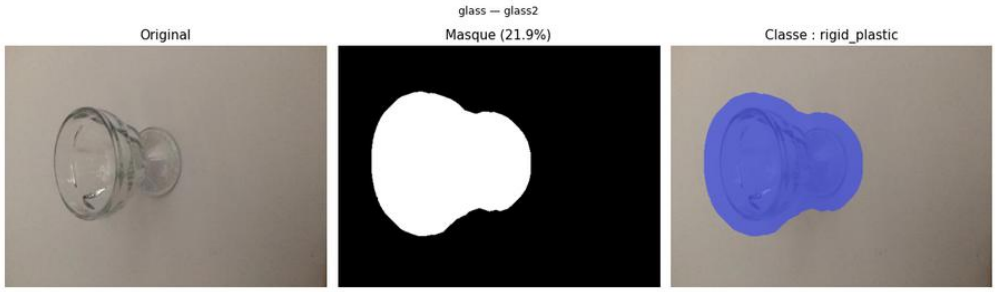

Figure 16 — Masque auto généré pour le verre dans le contexte fusionné : fond blanc bien détecté, objet correctement isolé

Figure 17 — Masque auto pour le carton : la détection est fiable sur fond blanc

4.5 Résultats de la meilleure configuration

La meilleure configuration obtenue en fusion utilise ZeroWaste complet (sampling par présence de classe, 30 images par classe) + Garbage Classification (30 images par classe

cible), avec poids manuels calibrés empiriquement (background 0.5, rigid_plastic 4.0, cardboard 2.0, metal 5.0, soft_plastic 3.5) et Focal Loss + Dice Loss à γ=2.0.

Classe	IoU	F1	mIoU global	Accuracy
background	0.847	0.917	0.313	84.8%
rigid_plastic	0.011	0.022	—	—
cardboard	0.421	0.592	—	—
metal	0.013	0.025	—	—
soft_plastic	0.274	0.430	—	—

Tableau 4 — Meilleurs résultats obtenus en configuration fusionnée (mIoU global = 0.313, mIoU sans fond = 0.180)

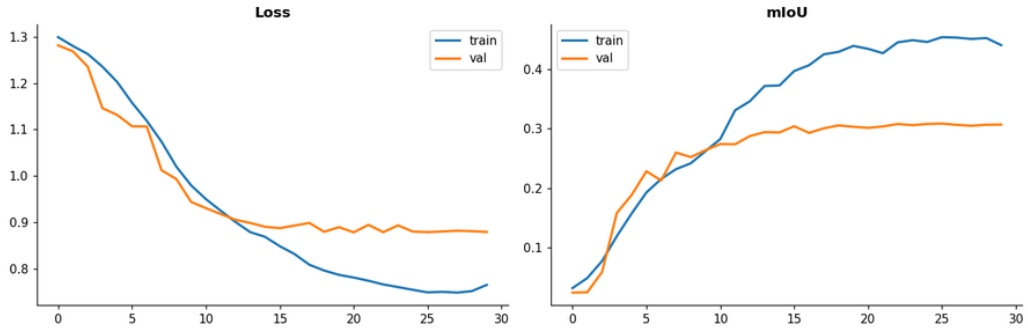

Figure 18 — Courbes d'entraînement de la configuration fusion (meilleure run) : 30 époques, val mIoU culminant à 0.31

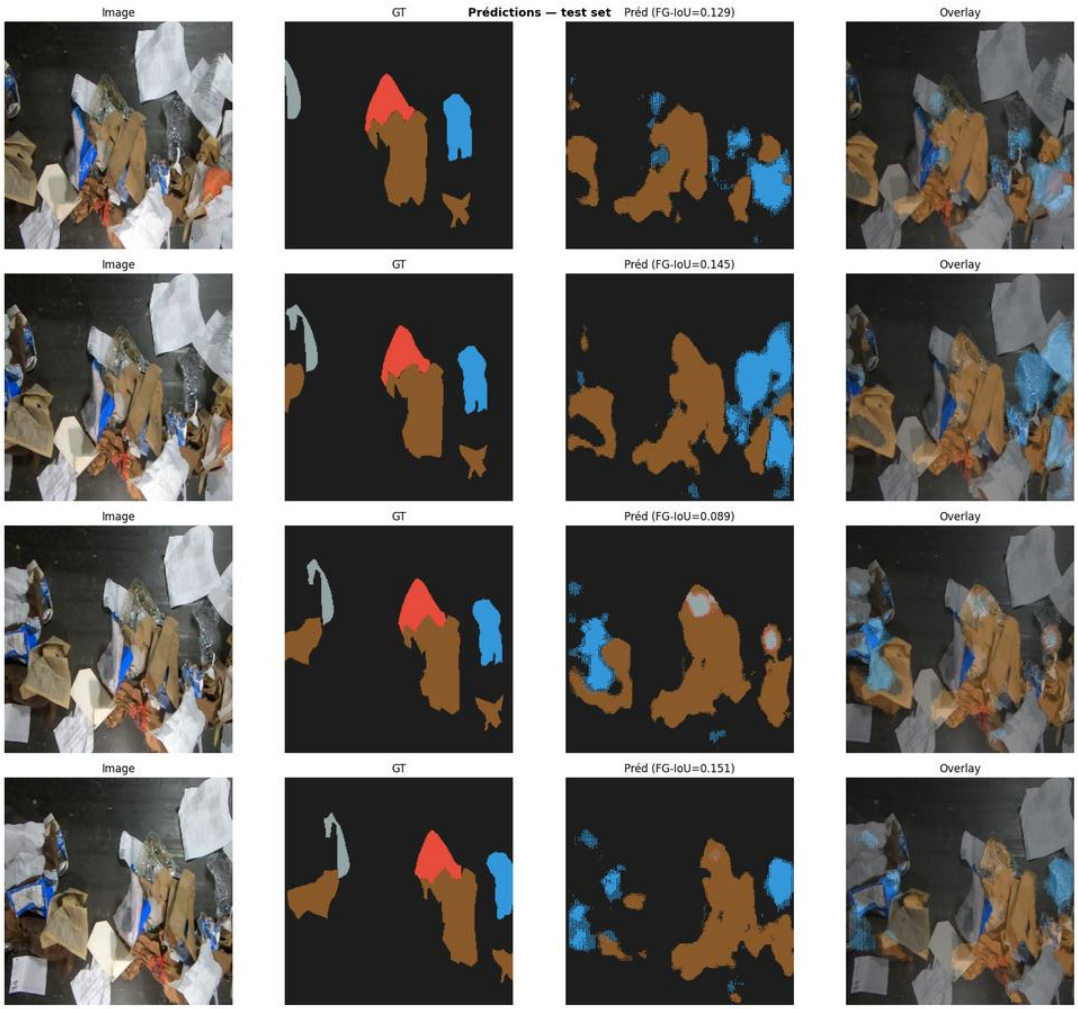

Figure 19 — Prédictions du modèle fusionné sur 4 images test : le fond et le carton sont correctement segmentés, mais rigid_plastic et metal restent absents des prédictions

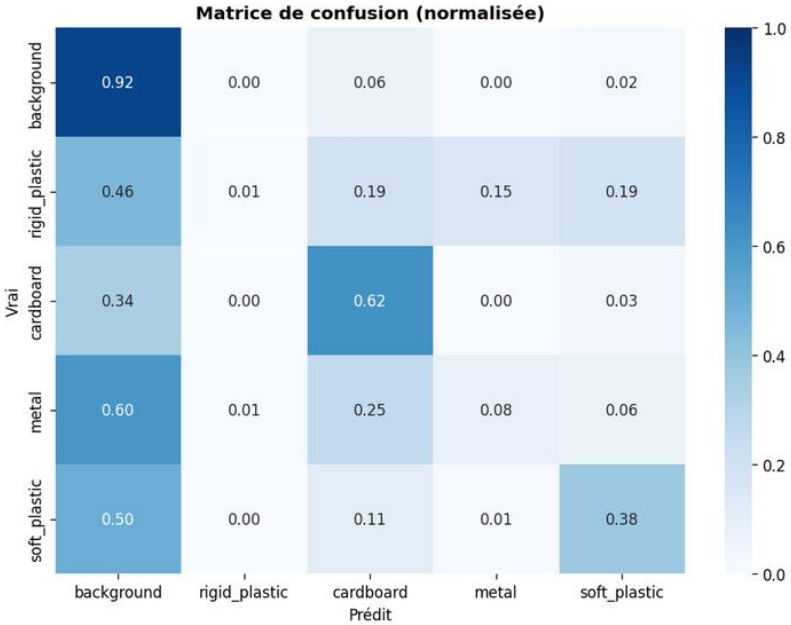

Figure 20 — Matrice de confusion normalisée : background et cardboard concentrent les prédictions correctes, les autres classes sont systématiquement confondues avec le background ou le cardboard

4.6 Analyse des résultats et facteurs limitants

Déséquilibre persistant des classes

Le mIoU sans fond de 0.180 révèle que le modèle segmente bien le fond (IoU=0.847) et le carton (IoU=0.421), mais échoue complètement sur rigid_plastic (0.011) et metal (0.013). Ces deux classes représentent moins de 1% des pixels dans les données d'entraînement, et même avec des poids de loss élevés, le signal de gradient reste trop faible pour que le modèle apprenne leurs caractéristiques visuelles distinctives.

Instabilité des poids de la loss

L'ajustement des poids de classe s'est révélé particulièrement délicat en configuration fusionnée. Chaque modification crée un effet de balancier entre classes : augmenter le poids de rigid_plastic provoque une sur-prédiction de cette classe au détriment du fond ou du carton. Les poids ont été calibrés manuellement par essais successifs, une approche laborieuse qui ne garantit pas une convergence stable.

Fonds visuellement incompatibles

La distinction fondamentale entre les deux datasets — fond blanc uniforme (Garbage) vs tapis roulant sombre et texturé (ZeroWaste) — crée un conflit de distribution que les augmentations et les poids ne peuvent pas résoudre complètement. Le modèle doit apprendre deux distributions de fond radicalement différentes, ce qui fragmente sa représentation interne de la classe background.

Volume de données insuffisant

La contrainte de 30 images par classe résulte en environ 150-300 images d'entraînement au total, ce qui est très faible pour la segmentation sémantique. À titre de comparaison, les modèles de référence sur ZeroWaste sont entraînés sur plusieurs milliers d'images annotées. Avec si peu de données, le modèle est structurellement incapable d'apprendre des représentations robustes pour les classes rares, indépendamment des réglages de la loss.

Redondance temporelle dans ZeroWaste

Même en utilisant un sampling par présence de classe plutôt que par classe dominante, les frames consécutifs de ZeroWaste introduisent de la redondance dans le train set. 30 images sélectionnées aléatoirement parmi une séquence peuvent inclure plusieurs frames quasi-identiques, ce qui réduit la diversité effective des exemples d'apprentissage.

Contraintes matérielles

L'ensemble des expériences a été conduit sur CPU, sans GPU disponible. Cette contrainte limite la taille des images (256×256 au lieu de 512×512 recommandé pour la segmentation), la taille des batches (16 au lieu de 32-64), et ralentit considérablement l'exploration des hyperparamètres. Un entraînement sur GPU permettrait d'augmenter la résolution, d'explorer davantage de configurations, et potentiellement d'utiliser SegFormer (modèle transformeur pré-entraîné sur segmentation qui n'a pas pu être testé faute de ressources suffisantes).

5. Conclusion et perspectives

5.1 Bilan

Ce projet a permis de construire un pipeline complet de segmentation sémantique de déchets, depuis la génération automatique de masques jusqu'à l'évaluation multi-classes, en passant par la gestion de datasets hétérogènes. Le modèle final (U-Net ResNet-18, configuration fusionnée) atteint un mIoU global de 0.313 et une précision pixel de 84.8%, avec une bonne segmentation du fond (0.847) et du carton (0.421).

Ces résultats restent insuffisants pour une application industrielle, principalement en raison du volume de données très limité et de l'incompatibilité des distributions entre les deux datasets. Les classes metal et rigid_plastic ne sont pratiquement pas apprises.

5.2 Pistes d'amélioration

- SegFormer (nvidia/mit-b2) : transformeur pré-entraîné sur ADE20K (segmentation réelle) qui comprend déjà les notions de fond, surface, objet. Ses performances avec peu de données sont documentées comme supérieures à U-Net. Le script train_segformer.py a été préparé mais n'a pas pu être exécuté faute de GPU.
- Augmentation des données ZeroWaste : utiliser tout le dataset original (4 503 images) au lieu de 30 par classe permettrait de mieux apprendre les classes rares, au prix d'un temps d'entraînement plus long.
- Séparation des modèles : entraîner un modèle spécialisé Garbage Classification et un modèle spécialisé ZeroWaste plutôt que de les fusionner, puis utiliser un classifieur de contexte pour sélectionner le bon modèle selon l'environnement.
- Annotation manuelle : disposer de masques annotés manuellement pour quelques centaines d'images Garbage Classification (plutôt que des masques auto) éliminerait la source principale de bruit dans les données d'entraînement.
- Hardware GPU : permettrait d'utiliser des images 512×512, des batches plus grands, et des modèles plus profonds, les trois facteurs les plus impactants pour la qualité de segmentation.

Ce projet illustre parfaitement les défis pratiques de la fusion de datasets hétérogènes en vision par ordinateur : la qualité et la cohérence des données ont autant d'impact que l'architecture du modèle, et les réglages fins (poids de loss, sampling) nécessitent un volume d'expériences difficile à conduire sans ressources GPU.